Semestrální práce

Karolína Šustrová, Kruh 446

2025-12-03

1. Rekapitulace zadání

Cílem této analýzy je porovnat míru exprese genu PPP6R3 v pěti různých tkáňových kulturách (akutní lymfoblastická leukémie - ALL, promyelocytická leukémie - PML, myelom - MYE, lymfom - LYM, chronická myeloidní leukémie - CML). Data představují logaritmus signálu z DNA čipu, jehož hodnota je úměrná logaritmu koncentrace mRNA.

2. Formulace hypotéz

Pro statistické ověření rozdílů použijeme analýzu rozptylu (ANOVA).

- **Nulová hypotéza (H_0):** Střední hodnoty exprese genu jsou ve všech pěti tkáňových kulturách (skupinách) shodné:

$$\mu_{ALL} = \mu_{PML} = \mu_{MYE} = \mu_{LYM} = \mu_{CML}$$

- **Alternativní hypotéza (H_1):** Alespoň jedna dvojice tkáňových kultur (skupin) se ve střední hodnotě liší (ne všechny průměry jsou stejné).

Hladinu významnosti stanovujeme na $\alpha = 0.05$.

3. Příprava dat

Data ze zadání převedeme do formátu “long” pro analýzu v R (jeden sloupec pro skupiny tkání, jeden pro hodnoty exprese).

```
# Vytvoření vektoru hodnot
hodnoty <- c(9.49401, 9.41961, 9.61037,  # ALL
             9.06951, 8.86489, 9.29840,  # PML
             8.74419, 8.76003, 9.23804,  # MYE
             8.72770, 8.90253, 9.17150,  # LYM
             8.71512, 8.91498, 8.90757)  # CML

# Vytvoření vektoru skupin
skupiny <- factor(rep(c("ALL", "PML", "MYE", "LYM", "CML"), each = 3))

# Vytvoření dataframu
df <- data.frame(Skupina = skupiny, Exprese = hodnoty)

# Kontrola dat
head(df)
```

```
##   Skupina Exprese
## 1     ALL 9.49401
## 2     ALL 9.41961
## 3     ALL 9.61037
## 4     PML 9.06951
## 5     PML 8.86489
## 6     PML 9.29840
```

```
summary(df)
```

```
##  Skupina    Exprese
##  ALL:3   Min.   :8.715
##  CML:3   1st Qu.:8.812
##  LYM:3   Median :8.915
##  MYE:3   Mean   :9.056
##  PML:3   3rd Qu.:9.268
##          Max.   :9.610
```

4. Vizualizace dat

Před provedením analýzy pomocí ANOVA je vhodné vizualizovat rozdělení dat pomocí boxplotu. Vzhledem k malému počtu pozorování ($n = 3$ pro každou skupinu) přidáme i body jednotlivých měření.

```
ggplot(df, aes(x = Skupina, y = Exprese, fill = Skupina)) +
  geom_boxplot(alpha = 0.3) +
  geom_jitter(width = 0.1, size = 2) +
  labs(title = "Exprese genu PPP6R3 v různých tkáňových kulturách",
       x = "Tkáňová kultura",
       y = "Logaritmus exprese") +
  theme_minimal()
```

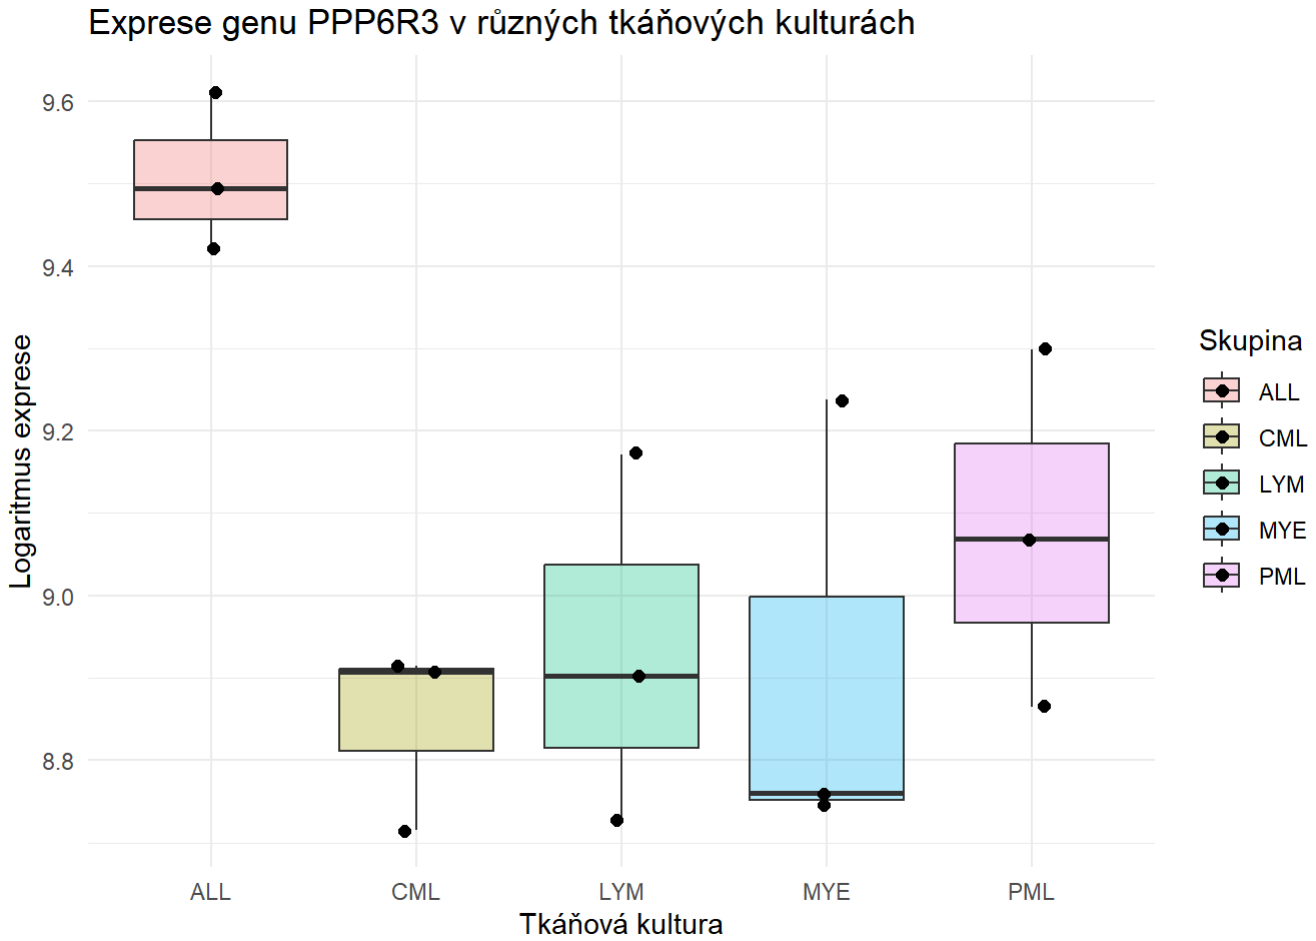

Z grafu je patrné, že skupina ALL má vyšší hodnoty exprese než ostatní skupiny. Naopak MYE a CML se zdají být nižší.

5. Ověření předpokladů ANOVA

Pro použití ANOVA je třeba ověřit její předpoklady:

1. **Nezávislost pozorování:** Zaručena designem studie (různé tkáňové kultury).
2. **Normalita dat (residuí):** Ověříme pomocí Shapiro-Wilkova testu na residuích modelu.
3. **Homogenita rozptylů (shoda rozptylů):** Ověříme pomocí Bartlettova testu (vhodný pro normální data).

```
# Vytvoření lineárního modelu pro ANOVA
model <- aov(Exprese ~ Skupina, data = df)

# 1. Test normality residuí (Shapiro-Wilk)
shapiro <- shapiro.test(residuals(model))
print(shapiro)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(model)
## W = 0.94027, p-value = 0.3858
```

```
# 2. Test homogenity rozptylů (Bartlett)
bartlett <- bartlett.test(Exprese ~ Skupina, data = df)
print(bartlett)
```

```
##
##  Bartlett test of homogeneity of variances
##
## data:  Exprese by Skupina
## Bartlett's K-squared = 2.4755, df = 4, p-value = 0.649
```

Interpretace ověření předpokladů:

- **Normalita:** p-hodnota Shapiro-Wilkova testu je 0.386. Hodnota je větší než 0.05, proto nezamítáme nulovou hypotézu o normalitě. Předpoklad normality je splněn.
- **Homogenita:** p-hodnota Bartlettova testu je 0.649. Hodnota je větší než 0.05, proto nezamítáme nulovou hypotézu o shodě rozptylů. Předpoklad homogenity je splněn.

6. Provedení ANOVA

Nyní můžeme provést parametrickou jednofaktorovou analýzu rozptylu (One-way ANOVA) pro testování našich hypotéz.

```
summary(model)
```

```
##             Df Sum Sq Mean Sq F value Pr(>F)
## Skupina      4 0.8519 0.21297   5.382 0.0142 *
## Residuals   10 0.3957 0.03957
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

7. Post-hoc test

ANOVA ukázala statisticky významné rozdíly mezi skupinami. Musíme určit, které konkrétní skupiny se liší. K tomu použijeme Tukeyův HSD test.

```
TukeyHSD(model)
```

```
##   Tukey multiple comparisons of means
##     95% family-wise confidence level
##
## Fit: aov(formula = Exprese ~ Skupina, data = df)
##
## $Skupina
##                diff        lwr         upr     p adj
## CML-ALL -0.66210667 -1.1966624 -0.12755091 0.0148720
## LYM-ALL -0.57408667 -1.1086424 -0.03953091 0.0342639
## MYE-ALL -0.59391000 -1.1284658 -0.05935424 0.0283574
## PML-ALL -0.43039667 -0.9649524  0.10415909 0.1334229
## LYM-CML  0.08802000 -0.4465358  0.62257576 0.9805360
## MYE-CML  0.06819667 -0.4663591  0.60275243 0.9924545
## PML-CML  0.23171000 -0.3028458  0.76626576 0.6260904
## MYE-LYM -0.01982333 -0.5543791  0.51473243 0.9999403
## PML-LYM  0.14369000 -0.3908658  0.67824576 0.8962386
## PML-MYE  0.16351333 -0.3710424  0.69806909 0.8466818
```

```
plot(TukeyHSD(model))
```

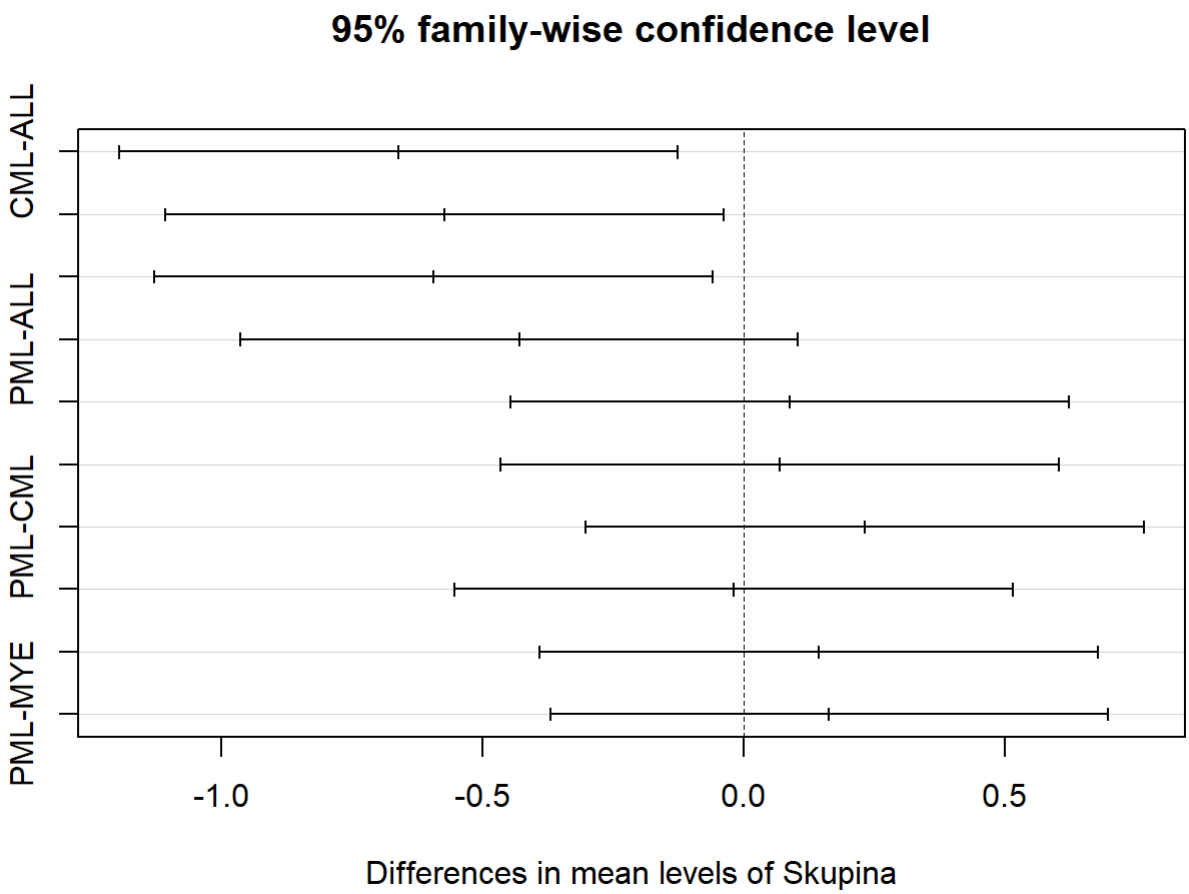

8. Závěr

Cílem této semestrální práce bylo porovnat míru exprese genu PPP6R3 v pěti různých tkáňových kulturách pomocí analýzy rozptylu (ANOVA).

Z výsledků jsme zjistili, že **existuje statisticky významný rozdíl** v expresi tohoto genu mezi zkoumanými skupinami ($F(4, 10) = 5.382, $p = 0.0142$).

Následná Post-hoc analýza pomocí Tukeyova HSD testu odhalila, že statisticky významný rozdíl (na hladině $p < 0.05$) je konkrétně mezi skupinami:

- **ALL a CML** ($p = 0.015$)
- **ALL a LYM** ($p = 0.034$)
- **ALL a MYE** ($p = 0.028$)

Skupina ALL vykazuje vyšší míru exprese genu PPP6R3 než skupiny CML, LYM a MYE. Ostatní rozdíly mezi skupinami nebyly statisticky významné.